

CleanSight 数据集与模型设计总结

[lhh010/cleansight-dataset](https://github.com/lhh010/cleansight-dataset)
<https://github.com/lhh010/cleansight-dataset>

一、数据来源

Label Studio (Project #10, 内镜清洗操作视频)

- └─ 17 个视频任务 (id=50~75)
- └─ 标注类型: videorectangle (目标检测 bbox) + timelinelabels (动作阶段)
- └─ 导出 JSON → cleansight-yolo-pipeline 流水线处理

二、数据集设计

2.1 分层结构

```
cleansight-yolo-pipeline/datasets/  
└─ long_brush_insert/          # 长刷插入阶段  
  │ └─ images/{train,val,test}/*.jpg  
  │ └─ labels/{train,val,test}/*.txt  
  └─ data.yaml  
└─ long_brush_withdraw/      # 长刷撤回阶段  
  │ └─ ...  
└─ air_injection/           # 气枪吹气阶段  
  │ └─ ...  
└─ flush/                   # 冲水冲洗阶段  
  └─ ...
```

设计原则：按动作阶段 (action phase) 作为数据集的第一层维度，每个阶段是一个独立的 YOLO 子数据集，可单独用于训练特定阶段的检测模型。

2.2 检测类别 (8 类，所有阶段共享)

class_id	标签	说明
0	hand	操作者手部
1	scope_control_body	内镜操控部
2	scope_mid_section	内镜中部
3	scope_distal_end	内镜头端

class_id	标签	说明
4	syringe	注射器
5	air_gun	气枪
6	short_brush	短毛刷
7	brush_tip_out	刷头外露

2.3 Split 划分

```
train (627 帧): task#59 (4807dbbe-clip) + task#68 (63a848d5-clip)
val   (191 帧): task#61 (65d70028-clip)
test  (  0 帧): (目前暂无, 待更多确认任务)
```

核心约束：按 LS 任务整段切分 —— 同一视频的所有帧永远在同一 split，杜绝时间相邻帧泄漏。

2.4 数据版本管理

```
本地：
  DATASET_STATUS.md           ← 项目根目录
  cleansight-yolo-pipeline/tracking.md ← 流水线自动生成

ModelScope:
  lhh010/cleansight-raw/      ← 原始 LS 导出 JSON + DATASET_STATUS.md
  lhh010/cleansight-yolo/     ← 处理后 YOLO 数据集 + tracking.md
    ├── long_brush_insert/
    ├── long_brush_withdraw/
    ├── air_injection/
    └── flush/
```

三、流水线设计

```
00_status.py      对账：导出/磁盘/白名单/split 四方对齐
01_pull_data.py   拉取原始视频
02_build_dataset.py 核心：旋转框 AABB 修正 → 阶段分割 → 抽帧 → YOLO 格式输出
03_train.py       YOLO 训练（每阶段独立模型）
04_validate.py    验收评估（PASS/FAIL 门禁）
```

四、关键设计决策

决策	说明
阶段分割优先	动作阶段作为数据集第一维度，因为不同阶段的目标分布和行为模式差异大，分开训练更精准
旋转框处理	LS 标注中的旋转矩形取 AABB（外接轴对齐矩形），兼容 YOLO 的 axis-aligned bbox 格式
整段路由防泄漏	同一视频不进多个 split，验证/测试指标可复现，不会被时间相邻帧"作弊"
确定性切分	hash(seed:stem) 分配 split，增量新增视频不打乱已有分配
白名单机制	config.yaml 的 only_videos 控制哪些任务进数据集，只有人工确认标注完成的任务才放行

五、模型设计

模型：YOLO11 nano (yolo11n.pt)
输入：640×640
策略：每阶段独立训练一个模型
long_brush_insert/ → runs/long_brush_insert/weights/best.pt
long_brush_withdraw/ → runs/long_brush_withdraw/weights/best.pt
air_injection/ → runs/air_injection/weights/best.pt
flush/ → runs/flush/weights/best.pt

六、当前数据覆盖矩阵

阶段	Train	Val	Test	合计	确认任务
long_brush_insert	217	42	0	259	59, 61, 68
long_brush_withdraw	123	38	0	161	59, 61, 68
air_injection	30	0	0	30	59 (仅有)
flush	257	111	0	368	61, 68
合计	627	191	0	818	3 个任务

待改进：

- 无 test 集（需更多确认任务）
- air_injection 无 val（只出现在 train 任务中）
- syringe、short_brush、air_gun、brush_tip_out 等类别样本稀少

七、Links

- Raw 数据集: [lhh010/cleansight-raw](#)
- YOLO 数据集: [lhh010/cleansight-yolo](#)