

CleanSight Dataset — 使用说明

内镜清洗操作视频的目标检测数据集构建与版本管理工具。

GitHub: [lhh010/cleansight-dataset](https://github.com/lhh010/cleansight-dataset)

目录

- [一、项目结构](#)
- [二、环境准备](#)
- [三、数据集概览](#)
- [四、快速开始](#)
- [五、添加新标注任务](#)
- [六、日常维护](#)
- [七、配置参考](#)
- [八、脚本速查](#)
- [九、版本管理](#)

一、项目结构

dataset/	
├─ config.py	# ModelScope / Label Studio 密钥（不入
git)	
├─ config.example.py	# 密钥模板
├─ DATASET_STATUS.md	# 数据集状态追踪表
├─ SUMMARY.md	# 数据集与模型设计总结
├─ cleansight-yolo-pipeline/	# ← 所有操作在此目录下执行
├─ config.yaml	# 中央配置 (groups, only_videos,
stride...)	
├─ splits.yaml	# Split 分配唯一真源
├─ completed_tasks.json	# 增量构建记录（自动生成）
└─ tracking.md	# 追踪表（自动生成）
└─ 00_status.py	# 对账：导出/磁盘/白名单/split 四方对齐
└─ 01_pull_data.py	# 下载 LS 视频到 raw/videos/
└─ 02_build_dataset.py	# 构建 group1_large / group2_small YOLO
数据集	
└─ 02_build_actionseq.py	# 构建 ActionSequence 动作阶段数据集

```

|   |   | 02b_augment.py      # 稀有类别数据增强（备用）
|   |   | 03_train.py        # YOLO 训练
|   |   | 04_validate.py     # 验收评估
|   |   |
|   |   | utils/
|   |   | | lsexport.py      # LS 导出 JSON 解析（旋转AABB、阶段提取）
|   |   | | split.py        # 确定性切分
|   |   | | stats.py        # 样本分布统计
|   |   | | common.py       # 公共工具
|   |   |
|   |   | raw/
|   |   | | exports/        # LS 导出 JSON
|   |   | | | videos/      # 下载的视频
|   |   | | datasets/      # group 数据集输出
|   |   | | datasets_actionseq/ # 动作阶段数据集输出
|   |
|   | upload_to_modelscope.py # 上传 raw 数据 → cleansight-raw
|   | upload_yolo_to_modelscope.py # 上传 group 数据集 → cleansight-yolo
|   | upload_actionseq_to_modelscope.py # 上传阶段数据集 → cleansight-
|   | ActionSequence

```

二、环境准备

```

cd cleansight-yolo-pipeline
pip install opencv-python-headless numpy pyyaml pillow ultralytics modelscope

# 如果训练/验证，还需 ultralytics（自动安装 PyTorch）

```

Label Studio 连接：确保 `config.py` 中配置了正确的 `LS_BASE_URL` 和 `LS_API_TOKEN`。

三、数据集概览

数据集	ModelScope	组织方式	类别
cleansight-raw	链接	原始 LS 导出 JSON	—
cleansight-yolo	链接	group1_large + group2_small	见下
cleansight-ActionSequence	链接	按动作阶段切分	8 类统一

group1_large

class_id	标签	说明
0	hand	操作者手部
1	scope_control_body	内镜操控部
2	scope_mid_section	内镜中部

group2_small

class_id	标签	说明
0	syringe	注射器
1	air_gun	气枪
2	scope_distal_end	内镜头端
3	short_brush	短毛刷
4	brush_tip_out	刷头外露

ActionSequence 阶段

阶段	说明
short_brush_cleaning	短刷清洁
long_brush_insert	长刷插入
long_brush_withdraw	长刷撤回
air_injection	气枪吹气
flush	冲水冲洗

四、快速开始

从零构建

```
cd cleansight-yolo-pipeline

# 1. 下载 LS 导出 JSON → raw/exports/
#  或从 LS 服务器拉取:
```

```

export LS_HOST=http://<LS地址>:8080  LS_TOKEN=<AccessToken>
python 01_pull_data.py

# 2. 对账 & 分配 split
python 00_status.py          # 查看状态
python 00_status.py --assign # 确定性回填 split

# 3. 构建两个数据集
python 02_build_dataset.py    # group 数据集 → datasets/
python 02_build_actionseq.py  # 动作阶段数据集 → datasets_actionseq/

# 4. 上传
cd ..
python upload_to_modelscope.py      # raw
python upload_yolo_to_modelscope.py # cleansight-yolo
python upload_actionseq_to_modelscope.py # cleansight-ActionSequence

```

五、添加新标注任务

当 Label Studio 上有新的确认标注完成的任务需要加入数据集：

步骤 1：重新导出 LS 数据

在 LS 网页端重新导出 Project #10 的 JSON，放入：

- cleansight-yolo-pipeline/raw/exports/
- raw-from Label Studio/

步骤 2：加入白名单

编辑 cleansight-yolo-pipeline/config.yaml，在 only_videos 末尾追加：

```

only_videos:
- 4807dbbe-clip      # task#59
- 65d70028-clip      # task#61
- 63a848d5-clip      # task#68
- xxxxxxxx-clip      # task#新ID ← 新增

```

步骤 3：下载视频 & 分配 split

```
cd cleansight-yolo-pipeline
```

```
# 下载新视频
export LS_HOST=... LS_TOKEN=...
python 01_pull_data.py

# 分配 split
python 00_status.py --assign
```

步骤 4：增量构建

```
# 增量模式：只处理新任务，已有任务秒级跳过
python 02_build_dataset.py
python 02_build_actionseq.py
```

如需全量重建： `python 02_build_dataset.py --force`

步骤 5：增量上传

```
cd ..
python upload_yolo_to_modelscope.py
python upload_actionseq_to_modelscope.py
```

ModelScope SDK 自带的 `.ms_upload_cache` 会自动只上传新增/变化的文件，已上传的秒级跳过。

六、日常维护

查看数据集状态

```
cd cleansight-yolo-pipeline
python 00_status.py
```

查看样本分布

```
python -c "from utils import stats; stats.main()"
```

同步 LS 最新数据

```
# 从 LS API 导出
python ../export_mix_label.py
```

```
# 或手动从 LS 网页下载 JSON，放入 raw/exports/
```

调整采样密度

编辑 `config.yaml` 的 `stride` 值，然后 `--force` 重建：

```
python 02_build_dataset.py --force
```

调整稀有类别阈值

编辑 `config.yaml` 的 `rare_threshold`，然后 `--force` 重建。

七、配置参考

config.yaml

```
groups:
  group1_large: [hand, scope_control_body, scope_mid_section]
  group2_small: [syringe, air_gun, scope_distal_end, short_brush,
brush_tip_out]

only_videos:                                # 只有这里列出的任务进数据集
- 4807dbbe-clip
- 65d70028-clip
- 63a848d5-clip

stride: 4                                   # 抽帧间隔（30fps 下  $\approx 7.5$  fps）
jpg_quality: 90

rare_dense_sampling: true # 稀有类别密集采样
rare_threshold: 200       # keyframe 数低于此值触发密集采样

train:
  model: yolo11n.pt
  epochs: 100
  imgsz: 640
  batch: 16
  patience: 20
```

splits.yaml

```
assignments:
  4807dbbe-clip_1781659328328_1781659467929: train
  65d70028-clip_1781661552468_1781661702909: val
  63a848d5-clip_1782695363948_1782695590302: train
```

- 已分配的视频 split 永不自动重排，人工可改
- 新增视频由 `--assign` 按 `hash(seed:stem)` 确定性分配

八、脚本速查

脚本	用途	常用参数
00_status.py	四方对账	<code>--assign</code> 回填 split
01_pull_data.py	下载 LS 视频	需要 <code>LS_HOST</code> + <code>LS_TOKEN</code> 环境变量
02_build_dataset.py	构建 group 数据集	<code>--auto-assign</code> <code>--force</code>
02_build_actionseq.py	构建动作阶段数据集	<code>--auto-assign</code> <code>--force</code>
02b_augment.py	旋转/缩放增强 (备用)	<code>--threshold=150</code> <code>--copies=3</code> <code>--dry-run</code>
03_train.py	YOLO 训练	<code>03_train.py group2_small</code>
04_validate.py	验收评估	输出 PASS/FAIL
upload_to_modelscope.py	上传 raw	—
upload_yolo_to_modelscope.py	上传 group 数据集	—
upload_actionseq_to_modelscope.py	上传阶段数据集	—

九、版本管理

增量构建机制

```
completed_tasks.json      ← 记录已处理任务的版本信息
    ↓
02_build_dataset.py 读取
```



强制全量重建

```
python 02_build_dataset.py --force
python 02_build_actionseq.py --force
```

以下情况需要 `--force`：

- 改了 stride、jpg_quality
- 改了 config.yaml 的 groups（增删类别）
- 修复了 lsexport.py 的核心逻辑（如旋转 AABB）
- 换了新的 LS 导出 JSON

追踪文件

文件	内容	位置
DATASET_STATUS.md	数据集状态表	项目根目录 + ModelScope
tracking.md	构建追踪表（自动生成）	cleansight-yolo-pipeline/
completed_tasks.json	增量构建记录	cleansight-yolo-pipeline/

Links

- Raw 数据：[lhh010/cleansight-raw](#)
- Group 数据集：[lhh010/cleansight-yolo](#)
- ActionSequence 数据集：[lhh010/cleansight-ActionSequence](#)
- 项目仓库：[lhh010/cleansight-dataset](#)